

NosAnalizamos

María Martínez Marí

2026-05-16

Carga de las librerías:

```
library(tidyverse)
```

```
## Warning: package 'tidyverse' was built under R version 4.5.2
```

```
## Warning: package 'readr' was built under R version 4.5.2
```

```
## Warning: package 'forcats' was built under R version 4.5.2
```

```
## Warning: package 'lubridate' was built under R version 4.5.2
```

```
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
```

```
## v dplyr      1.1.4      v readr      2.1.6
```

```
## v forcats    1.0.1      v stringr    1.5.2
```

```
## v ggplot2    4.0.0      v tibble     3.3.0
```

```
## v lubridate  1.9.4      v tidyr      1.3.1
```

```
## v purrr      1.1.0
```

```
## -- Conflicts ----- tidyverse_conflicts() --
```

```
## x dplyr::filter() masks stats::filter()
```

```
## x dplyr::lag()     masks stats::lag()
```

```
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
library(dplyr)
```

```
library(ggplot2)
```

```
library(lubridate)
```

```
library(pacman)
```

```
## Warning: package 'pacman' was built under R version 4.5.2
```

```
library(readr)
```

```
library(stringr)
```

Cargar el fichero de datos a un data frame.

```
# o read.delim()
fich<- read_tsv("data/NosAutoanalizamos2022 - Hoja1.tsv")
```

```
## New names:
## Rows: 88 Columns: 21
## -- Column specification
## ----- Delimiter: "\t" chr
## (21): 8-6-2002, ...2, ...3, ...4, Fecha, Fecha de nacimiento en formato ...
## i Use 'spec()' to retrieve the full column specification for this data. i
## Specify the column types or set 'show_col_types = FALSE' to quiet this message.
## * ' -> '...2'
## * ' -> '...3'
## * ' -> '...4'
## * ' -> '...7'
## * ' -> '...8'
## * ' -> '...9'
## * ' -> '...10'
## * ' -> '...11'
## * ' -> '...12'
## * ' -> '...13'
## * ' -> '...14'
## * ' -> '...15'
## * ' -> '...16'
## * ' -> '...17'
## * ' -> '...18'
## * ' -> '...19'
## * ' -> '...20'
## * ' -> '...21'
```

```
da<-as.data.frame(fich)
head(da, 3)
```

```
##      8-6-2002 ...2 ...3 ...4          Fecha
## 1  sercam3 <NA>  .. <NA> Identificación
## 2      19 <NA> <NA> <NA>              Age
## 3 Masculino <NA> <NA> <NA>              Sex
##      Fecha de nacimiento en formato dd-mm-yyyy ...7 ...8 ...9 ...10 ...11 ...12
## 1      Usuario de correo UV. martsobm <NA> <NA> <NA> <NA> <NA> <NA>
## 2      Edad en años. <NA> <NA> <NA> <NA> <NA> <NA>
## 3      Sexo: Femenino, Masculino <NA> <NA> <NA> <NA> <NA> <NA>
##      ...13 ...14 ...15 ...16 ...17 ...18 ...19 ...20 ...21
## 1 <NA> <NA> <NA> <NA> <NA> <NA> <NA> <NA> <NA>
## 2 <NA> <NA> <NA> <NA> <NA> <NA> <NA> <NA> <NA>
## 3 <NA> <NA> <NA> <NA> <NA> <NA> <NA> <NA> <NA>
```

```
# El df contendrá las columnas con variables y las filas que contengan datos.
# Vemos que el nombre de las columnas están en la fila 24:
```

```
# Seleccionamos desde la fila 25 hasta el final:
datos<- da[24:nrow(da),]
colnames(datos)<- datos[1,]
datos<-datos[-1,] #Quitamos la fila 24
```

```
datos <- datos %>%
  rename(Registro = 1) # Esto cambia la columna 1 por "Registro"

head(datos, 5)
```

```
##      Registro FechaNac(DD-MM-YYY)      Id Age Sex Wr.Hnd      NW.Hnd
## 25 Registro Ejemplo      20-01-1969 martsobm 53  M   22 Derecha
## 26      <NA>      18-11-2003 pedelu 18  M   18 Derecha
## 27      <NA>      19-08-2003 salgis 18  M   19 Derecha
## 28      <NA>      15-03-2003 garfal 18  F   18 Izquierda
## 29      <NA>      24-06-2003 silobor 18  F   18 Derecha
##      Fold Pulse      Clap Exer Smoke Height ALG  ANM  FP  DCS  MD HSt
## 25 Izquierdo  65 Der s Izq  2  No   178 NP  7  6  4  3.8  5
## 26 Izquierdo  50 Der s Izq  5  No   180 10 9.62 NP  8.3 9.3 1.5
## 27 Derecho   73 Der s Izq  0  No   173 2.8  4 <NA> 5.11 5.55 2
## 28 Izquierdo  71 Der s Izq  0  No   163 6.4 6.65 <NA> 6.5 5.8 3
## 29 Derecho   66 Der s Izq  0  No   164 7.1 7.8 <NA> 7.5 7 3
##      Hwork
## 25 37,5
## 26 10
## 27 0
## 28 8
## 29 1
##
## Comentarios
## 25 Es la primera toma de contacto con el análisis de datos reales. Me resultará de gran utilidad.
## 26 Continúa de DCS pero menos teórico y más práctico
## 27 Parece interesante.
## 28 Seguimiento de DCS, pero parece un poco más práctico
## 29 Parece denso y complejo
```

4. Eliminamos el usuario cuyo id es martsobm:

```
datos_final <- datos %>%
  filter(Id != "martsobm")

head(datos_final)
```

```
##      Registro FechaNac(DD-MM-YYY)      Id Age Sex Wr.Hnd      NW.Hnd      Fold
## 1      <NA>      18-11-2003 pedelu 18  M   18 Derecha Izquierdo
## 2      <NA>      19-08-2003 salgis 18  M   19 Derecha Derecho
## 3      <NA>      15-03-2003 garfal 18  F   18 Izquierda Izquierdo
## 4      <NA>      24-06-2003 silobor 18  F   18 Derecha Derecho
## 5      <NA>      21-6-2003 jamarlli 18  M   16 Derecha Derecho
## 6      <NA>      13-05-2003 mabalo3 18  M   20 Izquierda Izquierdo
##      Pulse      Clap Exer Smoke Height ALG  ANM  FP  DCS  MD HSt Hwork
## 1  50 Der s Izq  5  No   180 10 9.62 NP  8.3 9.3 1.5 10
## 2  73 Der s Izq  0  No   173 2.8  4 <NA> 5.11 5.55 2 0
## 3  71 Der s Izq  0  No   163 6.4 6.65 <NA> 6.5 5.8 3 8
## 4  66 Der s Izq  0  No   164 7.1 7.8 <NA> 7.5 7 3 1
```

```
## 5      60 Der s Izq      4      No      180 9.5  9.2  9.5  9.0  9.4  5      3
## 6      96 Izq s Der      6      No      175 1.9  3.4 <NA> 5.2  2.2  1      0
##
## 1
## 2
## 3
## 4
## 5
## 6 Antes que nada tengo que saber bien de qué trata la asignatura porque de momento no la entiendo muy
```

5. Seleccionar las columnas con las calificaciones y adecúalas.

```
# Separador decimal es el punto.
# Si alguna calificación es NC se sustituirá por 3.
# Valor no conocido se sustituirá por NA

# Creamos el vector con el nombre de las columnas que contienen las calificaciones.
variables_notas <- c("ALG", "ANM", "FP", "DCS", "MD")

# Vemos que de las columnas 14 a la 20 son notas
notas <- datos_final %>%
  # mutate() Modificamos las columnas
  # across() se aplica en varias columnas la misma operacion
  # all_of () que trabajamos solo con esas asignaturas.
  # ifelse(condicion, valor si sí, valor sino)
  # El primer punto significa todas las columnas
  # El tercer punto indica que se quede como está
  # ~ este símbolo indica que ahora viene una función
  mutate(across(all_of(variables_notas),
    ~ ifelse(. == "NC", "3", .))) %>%

  # Expresión regular: Permite números como 5, 7.2 etc.

  mutate(across(all_of(variables_notas),
    ~ ifelse(str_detect(., "[0-9]+(\\.[0-9]+)?$"), ., NA))) %>%

  # convertir a numérico

  mutate(across(all_of(variables_notas), as.numeric))

head(notas)
```

```
##      Registro FechaNac(DD-MM-YYY)      Id Age Sex Wr.Hnd      NW.Hnd      Fold
## 1      <NA>      18-11-2003      pedelu 18  M      18      Derecha Izquierdo
## 2      <NA>      19-08-2003      salgis 18  M      19      Derecha  Derecho
## 3      <NA>      15-03-2003      garfal 18  F      18 Izquierda Izquierdo
## 4      <NA>      24-06-2003      silobor 18  F      18      Derecha  Derecho
## 5      <NA>      21-6-2003      jamarlli 18  M      16      Derecha  Derecho
## 6      <NA>      13-05-2003      mabalo3 18  M      20 Izquierda Izquierdo
##      Pulse      Clap Exer Smoke Height  ALG  ANM  FP  DCS  MD HSt Hwork
```

```
## 1    50 Der s Izq    5    No    180 10.0 9.62  NA 8.30 9.30 1.5    10
## 2    73 Der s Izq    0    No    173  2.8 4.00  NA 5.11 5.55  2     0
## 3    71 Der s Izq    0    No    163  6.4 6.65  NA 6.50 5.80  3     8
## 4    66 Der s Izq    0    No    164  7.1 7.80  NA 7.50 7.00  3     1
## 5    60 Der s Izq    4    No    180  9.5 9.20  9.5 9.00 9.40  5     3
## 6    96 Izq s Der    6    No    175  1.9 3.40  NA 5.20 2.20  1     0
##
## 1
## 2
## 3
## 4
## 5
## 6 Antes que nada tengo que saber bien de qué trata la asignatura porque de momento no la entiendo muy
```

```
saveRDS(notas, "Notas.Rdata")
```

6. Obtener una tabla de estadísticos de estas variables.

Primera columna las asignaturas y las siguientes asignaturas que correspondan con los estadísticos.

```
est <- notas[, 14:18]

tabla_est <- data.frame(
  Asignatura = names(est),
  # con sapply() aplicamos una funcion a cada columna y devuelve el resultado
  Minimo = sapply(est, min, na.rm = TRUE),
  P25 = sapply(est, quantile, probs = 0.25, na.rm = TRUE),
  Mediana = sapply(est, median, na.rm = TRUE),
  Media = sapply(est, mean, na.rm = TRUE),
  DesvTipica = sapply(est, sd, na.rm = TRUE),
  P75 = sapply(est, quantile, probs = 0.75, na.rm = TRUE),
  Maximo = sapply(est, max, na.rm = TRUE)
)

tabla_est <- tabla_est %>%
  mutate(across(where(is.numeric), ~ round(.x, 2)))

tabla_est
```


```
##      Asignatura Minimo  P25 Mediana Media DesvTipica  P75 Maximo
## ALG          ALG    1.9 6.00    6.72  6.41      1.65 7.50 10.00
## ANM          ANM    3.4 6.97    7.90  7.61      1.45 8.50  9.81
## FP           FP    3.0 3.53    6.00  5.77      2.25 7.25  9.50
## DCS          DCS    3.0 6.79    7.65  7.42      1.36 8.30  9.80
## MD           MD    1.5 5.47    6.40  6.12      1.99 7.41  9.50
```

7. la función `ggpairs` de la librería `GGally` y representa las relaciones entre todas las variables.

```
library(GGally)
```


```
## Warning: package 'GGally' was built under R version 4.5.3
```

```
est %>% pairs()
```



#8. Determina las matrices de correlación y covarianza de dichas variables, con las opciones “Spearman” y “Pearson” e indica qué pares de variables tienen la correlación más alta.

```
# Matriz de correlación
est %>% ggcorr(label = TRUE)
```



Vemos que el par de variables que tienen una mayor correlación es FP con MD, MD y ALG y ALG con ANM.

Matriz de covarianza:

```
cov(est, use= "complete.obs") %>% round(2)
```


```
##      ALG  ANM  FP  DCS  MD
## ALG 2.68 1.58 2.03 0.81 2.23
## ANM 1.58 1.86 1.89 1.13 1.45
## FP  2.03 1.89 5.08 1.70 2.77
## DCS 0.81 1.13 1.70 2.22 1.27
## MD  2.23 1.45 2.77 1.27 2.90
```

9. Representa en una misma gráfica los boxplots con las calificaciones obtenidas en las diferentes asignaturas.

```
Asignatura_Nota<-pivot_longer(est, cols= names(est),
                              names_to= "Asignatura",
                              values_to= "Nota")
```

```
Asignatura_Nota%>%
  ggplot(aes(x=Asignatura, y=Nota, color= Asignatura)) + geom_boxplot()
```


```
## Warning: Removed 50 rows containing non-finite outside the scale range
## ('stat_boxplot()').
```



10. Añade la variable sexo al conjunto de datos y realiza la representación del boxplot de calificaciones por asignatura coloreando según dicha variable.

```
pivot_longer(notas, cols = names(notas[,14:18]),
              names_to = "Asignatura",
              values_to = "Nota") %>%
  ggplot(aes(Asignatura, Nota, fill = Sex)) +
  geom_boxplot()
```

```
## Warning: Removed 50 rows containing non-finite outside the scale range
## ('stat_boxplot()').
```

11. Selecciona los alumnos que tengan calificaciones en todas las asignaturas y represéntalas gráficamente. En el eje X aparecerá el usuario del alumno (girado 90°) y en el eje Y la calificación numérica con un color distinto para cada asignatura. Se mostrará un diagrama de líneas, que una las calificaciones de una misma asignatura para todos los alumnos así como un punto, por asignatura (del mismo color que las líneas), para cada asignatura y alumno.


```
names(notas)
```

```
## [1] "Registro"          "FechaNac(DD-MM-YYY)" "Id"
## [4] "Age"               "Sex"                  "Wr.Hnd"
## [7] "NW.Hnd"            "Fold"                 "Pulse"
## [10] "Clap"              "Exer"                 "Smoke"
## [13] "Height"            "ALG"                  "ANM"
## [16] "FP"                "DCS"                  "MD"
## [19] "HSt"               "Hwork"                "Comentarios"
```

```
alumnos <- notas %>% select(Id, ALG, ANM, FP, DCS, MD) %>% filter(complete.cases())
col_nota<- alumnos %>% pivot_longer(cols = c(ALG, ANM, FP, DCS, MD),
                                   names_to= "Asignatura",
                                   values_to = "Nota")
```

```
col_nota %>%
  # group = Asignatura así une puntos en líneas
  ggplot(aes(x = Id, y = Nota, color = Asignatura, group = Asignatura)) +
  geom_line() +
```

```
geom_point() +
theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust = 1))
```



```
fich2<-read_tsv("./data/NosAutoanalizamos2026 - NosAutoanalizamos.tsv")
```

```
## New names:
## Rows: 87 Columns: 23
## -- Column specification
## ----- Delimiter: "\t" chr
## (22): ...1, ...2, ...3, Fecha, 04-01-2006, ...6, ...7, ...8, ...9, ...10... lg1
## (1): ...22
## i Use 'spec()' to retrieve the full column specification for this data. i
## Specify the column types or set 'show_col_types = FALSE' to quiet this message.
## * '' -> '...1'
## * '' -> '...2'
## * '' -> '...3'
## * '' -> '...6'
## * '' -> '...7'
## * '' -> '...8'
## * '' -> '...9'
## * '' -> '...10'
## * '' -> '...11'
## * '' -> '...12'
## * '' -> '...13'
## * '' -> '...14'
```

```
## * ' -> '...15'
## * ' -> '...16'
## * ' -> '...17'
## * ' -> '...18'
## * ' -> '...19'
## * ' -> '...20'
## * ' -> '...21'
## * ' -> '...22'
## * ' -> '...23'
```

```
df2<-as.data.frame(fich2)
```

```
# Realizamos el mismo proceso:
# Seleccionamos desde la fila 25 hasta el final:
datos2<- df2[24:nrow(df2),]
colnames(datos2)<- datos2[2,]
datos2<-datos2[-(1:3),] #Quitamos la fila 24, 25 y 26

head(datos2)
```

```
##      FechaNac(DD-MM-YYY)      Id Age Sex Wr.Hnd      NW.Hnd      Fold Pulse
## 27      11-03-2004 sorivi  21  F   16,6 Derecha Derecho  68
## 28      11-03-2006 magiflo 19  M    20 Derecha Derecho  59
## 29      18-09-2006 fuenar2 19  F    20 Derecha Izquierdo  60
## 30      04-12-2006 lauhori 19  F    20 Derecha Izquierdo  60
## 31      31-7-2007 Jorica3  18  M   18.8 Izquierda Derecha  68
## 32      05-12-2006 bevili  19  F    20 Derecha Izquierdo  60
##      Clap Exer Smoke Height ALG ANM FP DCS MD HSt Hwork      DNI
## 27 Izq s Der 3 No 156 NC 7,9 NC 9 7,8 3,5 28 23886807L
## 28 Der s Izq 6 No 173 NC <NA> NC <NA> 6,2 3 0 74395855D
## 29 Der s Izq 5 No 170 <NA> <NA> <NA> <NA> <NA> 2 0 49849495P
## 30 Der s Izq 4 No 180 <NA> <NA> <NA> <NA> <NA> 3 0 32735426D
## 31 Ninguna 6 No 184 3.4 7.6 <NA> 5 5 2 30 54414483W
## 32 Der s Izq 0 No 169 3,2 6,9 <NA> 4 4 4 0 53885132L
```

```
##
## 27 Tratamiento de los
## 28 Tratamiento de Datos es importante para poder preparar conjuntos de datos para luego trabajar con
## 29 Espero aprobar por fin esta asignatura. Esta a
## 30 Tratamiento de datos es un
## 31 De momento, tratamiento de datos es la asignatura
## 32
## NA <NA>
## 27 NA <NA>
## 28 NA <NA>
## 29 NA <NA>
## 30 NA <NA>
## 31 NA <NA>
## 32 NA <NA>
```

```
# Cambiamos el nombre de la columna
colnames(datos2)[1] <- "FechaNac"
```

12. Sin hacer ninguna modificación en el código utiliza el fichero correspondiente al año 2026 y compara los resultados con los del curso 2022

```
col_nota2 <- datos2 %>%
  select(Id, ALG, ANM, FP, DCS, MD) %>%
  filter(complete.cases(.)) %>%
  mutate(across(c(ALG, ANM, FP, DCS, MD), as.numeric)) %>%
  pivot_longer(cols = c(ALG, ANM, FP, DCS, MD),
               names_to = "Asignatura",
               values_to = "Nota") %>%
  mutate(Curso = "2026")
```

```
## Warning: There were 5 warnings in 'mutate()'.
## The first warning was:
## i In argument: 'across(c(ALG, ANM, FP, DCS, MD), as.numeric)'.
## Caused by warning:
## ! NAs introducidos por coerción
## i Run 'dplyr::last_dplyr_warnings()' to see the 4 remaining warnings.
```

```
col_nota2
```

```
## # A tibble: 75 x 4
##   Id      Asignatura  Nota Curso
##   <chr>   <chr>      <dbl> <chr>
## 1 sorivi  ALG          NA  2026
## 2 sorivi  ANM          NA  2026
## 3 sorivi  FP           NA  2026
## 4 sorivi  DCS           9  2026
## 5 sorivi  MD           NA  2026
## 6 diazrua ALG          NA  2026
## 7 diazrua ANM          NA  2026
## 8 diazrua FP           8  2026
## 9 diazrua DCS           8  2026
## 10 diazrua MD          7  2026
## # i 65 more rows
```

```
c<-col_nota %>% mutate(Curso= "2022")
c
```

```
## # A tibble: 100 x 4
##   Id      Asignatura  Nota Curso
##   <chr>   <chr>      <dbl> <chr>
## 1 jamarlli ALG          9.5  2022
## 2 jamarlli ANM          9.2  2022
## 3 jamarlli FP          9.5  2022
## 4 jamarlli DCS           9  2022
## 5 jamarlli MD          9.4  2022
## 6 esaia    ALG          6.39 2022
## 7 esaia    ANM          7.23 2022
```

```
## 8 esaia FP 3.7 2022
## 9 esaia DCS 6.1 2022
## 10 esaia MD 6.3 2022
## # i 90 more rows
```


```
# Unimos los df para hacer la grafica
total<- bind_rows(col_nota2, c)
head(total)
```

```
## # A tibble: 6 x 4
##   Id      Asignatura  Nota Curso
##   <chr>   <chr>      <dbl> <chr>
## 1 sorivi ALG          NA 2026
## 2 sorivi ANM          NA 2026
## 3 sorivi FP          NA 2026
## 4 sorivi DCS          9 2026
## 5 sorivi MD          NA 2026
## 6 diazrua ALG          NA 2026
```

```
total %>%
  ggplot(aes(x = Id, y = Nota, color = Asignatura, group = Asignatura)) +
  geom_line() +
  geom_point() +
  facet_wrap(~Curso) +
  theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust = 1))
```

```
## Warning: Removed 9 rows containing missing values or values outside the scale range
## ('geom_line()').
```

```
## Warning: Removed 50 rows containing missing values or values outside the scale range
## ('geom_point()').
```



13. Responde a las siguientes preguntas, utilizando los datos del curso 2026. Ten en cuenta que deberás hacer correcciones en los datos en aquellos casos en los que los valores introducidos contengan errores. Por ejemplo si en las instrucción se indica que para el sexo de nacimiento los valores posibles son M y F, cualquier otro valor deberá ser corregido. Si la corrección no es posible sustituye por NA. Debes justificar todas las cuestiones con los datos disponibles.

a. ¿Qué edad, expresada en años (con decimales) tiene el alumno más joven a fecha 01/02/2026.

```
names(datos2)
```

```
## [1] "FechaNac" "Id" "Age" "Sex" "Wr.Hnd"
## [6] "NW.Hnd" "Fold" "Pulse" "Clap" "Exer"
## [11] "Smoke" "Height" "ALG" "ANM" "FP"
## [16] "DCS" "MD" "HSt" "Hwork" "DNI"
## [21] "Comentarios" "NA" NA
```

```
head(datos2)
```

```
##      FechaNac      Id Age Sex Wr.Hnd      NW.Hnd      Fold Pulse      Clap Exer
## 27 11-03-2004 sorivi 21  F   16,6   Derecha   Derecho   68 Izq s Der    3
## 28 11-03-2006 magiflo 19  M    20   Derecha   Derecho   59 Der s Izq    6
## 29 18-09-2006 fuenar2 19  F    20   Derecha Izquierdo   60 Der s Izq    5
## 30 04-12-2006 lauhori 19  F    20   Derecha Izquierdo   60 Der s Izq    4
## 31 31-7-2007 Jorica3 18  M   18.8 Izquierda Derecha   68 Ninguna   6
## 32 05-12-2006 bevili 19  F    20   Derecha Izquierdo   60 Der s Izq    0
##      Smoke Height  ALG  ANM  FP  DCS  MD HSt Hwork      DNI
## 27   No    156   NC  7,9  NC   9  7,8 3,5   28 23886807L
## 28   No    173   NC <NA>  NC <NA> 6,2  3    0 74395855D
## 29   No    170 <NA> <NA> <NA> <NA> <NA> 2    0 49849495P
## 30   No    180 <NA> <NA> <NA> <NA> <NA> 3    0 32735426D
## 31   No    184  3.4  7.6 <NA>  5    5  2   30 54414483W
## 32   No    169  3,2  6,9 <NA>  4    4  4    0 53885132L
##
## 27
## 28 Tratamiento de Datos es importante para poder preparar conjuntos de datos para luego trabajar con
## 29
## 30      Espero aprobar por fin esta asignatura. Esta a
## 31      Tratamiento de datos es un
## 32      De momento, tratamiento de datos es la asignatura a
##      NA <NA>
## 27 NA <NA>
## 28 NA <NA>
## 29 NA <NA>
## 30 NA <NA>
## 31 NA <NA>
## 32 NA <NA>
```

```
ncol(datos2)
```

```
## [1] 23
```

```
datos2<-datos2[,-(22:23)]
```

```
# Definimos la fecha objetivo
fecha_objetivo <- dmy("01-02-2026")
fecha_objetivo
```

```
## [1] "2026-02-01"
```

```
datos2$FechaNac <- dmy(datos2$FechaNac)
```

```
# Calculamos edad exacta a 01/02/2026
datos2 <- datos2 %>%
  mutate(
    EDAD_decimales = as.numeric(fecha_objetivo - FechaNac) / 365.25) %>% arrange(EDAD_decimales)
head(datos2)
```

```
##      FechaNac      Id Age Sex Wr.Hnd  NW.Hnd      Fold Pulse      Clap Exer
## 1 2007-12-19 gipicar  18  F   19 Derecha  Derecho   71 Der s Izd   2
## 2 2007-12-17 nihesan  18  M   22 Derecha  Derecho   70 Der s Izq   4
## 3 2007-12-14 mapeso5  18  M   19 Derecha Izquierdo  55 Izq s Der   5
## 4 2007-12-03 zarjuan  18  M   18 Derecha  Derecha   54 Derecha  6
## 5 2007-12-03 aceva   18  M   21 Derecha Izquierdo  66 Izq s Der   4
## 6 2007-11-28 a29     18  M   20 Derecha Izquierdo  67 Izq s Der   5
##      Smoke Height ALG ANM  FP DCS  MD HSt Hwork      DNI
## 1    No    157 7,2  6 <NA>  4 6,2  3    0 73664304L
## 2    No    182 7.5 8,1 <NA>  NC 6,4  2    0 54290706B
## 3    No    179  NC  NC <NA>  4 5,7  2    0 23888492W
## 4    No    185  NC 7,4  NC  NC 7,3  0    0 54748087Z
## 5    No    175 5,4 10 <NA> 5,2 7,3  4    8 46275240E
## 6    No    172 6,8 6,3 <NA> 7,6 6,6  1    3 54290100A
##
## 1
## 2
## 3
## 4
## 5 Tiene muy buena pinta. Espero no arrepentirme de pensar que esto puede llegar a ser "fácil" y "div
## 6
##      EDAD_decimales
## 1      18.12183
## 2      18.12731
## 3      18.13552
## 4      18.16564
## 5      18.16564
## 6      18.17933
```

```
#La edad del usuario más joven es 18.12183
```

b. Cuántos alumnos simultanean trabajo y estudios.

```
names(datos2)
```

```
## [1] "FechaNac"      "Id"             "Age"            "Sex"
## [5] "Wr.Hnd"        "NW.Hnd"         "Fold"           "Pulse"
## [9] "Clap"          "Exer"           "Smoke"          "Height"
## [13] "ALG"           "ANM"            "FP"             "DCS"
## [17] "MD"            "HSt"            "Hwork"          "DNI"
## [21] "Comentarios"   "EDAD_decimales"
```

```
datos2$Hwork<-as.numeric(datos2$Hwork)
```

```
t_e<- datos2 %>% filter(Hwork>0) %>% distinct()
nrow(t_e) # 14 alumnos realizan trabajos y estudios
```

```
## [1] 14
```

c. Hay más hombres o más mujeres fumadoras.


```
fumadores<- datos2 %>% filter(Smoke== "Si")
fumadores
```

```
##      FechaNac      Id Age Sex Wr.Hnd    NW.Hnd      Fold Pulse      Clap Exer
## 1 2007-06-03 marlau6  18  M    20   Derecha Izquierdo    60 Izq s Der    4
## 2 2007-03-31  isago2  18  M    22   Derecha Izquierdo    65 Der s Izq    3
## 3 2007-03-30 antanuez 18  M    20 Izquierda  Derecho    59 Izq s Der    3
## 4 2007-02-22 majuanm4 19  M    19   Derecha  Derecho    60 Der s Izq    5
## 5 2006-11-01 seruiza2 19  M    19 Izquierda Izquierda    69 Izq s Der    0
## 6 2006-07-20 anfuen  19  M    20   Derecha  Derecho    65 Der s Izq    3
## 7 2002-12-02  amirt   23  M    18 Izquierda Izquierda    70 Izq s Der    3
##      Smoke Height  ALG  ANM  FP  DCS  MD HSt Hwork      DNI
## 1     Si    185   7,5  6,5 <NA> 8,2  7,8  2    0 20986029R
## 2     Si    181   2.5  4.7 <NA>  6  7.5  3    0 73599010E
## 3     Si    182    NC   NC <NA>  8  7,5 0,5  9 53885739M
## 4     Si    175   8,8  7,3 <NA> 7,5  7,5 0,5 15 54015599F
## 5     Si    174   8.5  8.1  8.6 8.4  7.4  4    0 5459375P
## 6     Si    178    NC   NC   NC  NC  NC  2    0 20869026E
## 7     Si    178 <NA> <NA> <NA> <NA> <NA> 2    0    <NA>
##
## 1
## 2
## 3
## 4
## 5 Me gusta que enfoque lleva pero me gustaria mas que fuese en python para mayor integracion a poste
## 6
## 7
##      EDAD_decimales
## 1      18.66667
## 2      18.84189
## 3      18.84463
## 4      18.94319
## 5      19.25257
## 6      19.53730
## 7      23.16769
```

```
table(fumadores$Sex)
```

```
##
## M
## 7
```

```
# Vemos que solo hay hombres fumadores.
```

d. Cuál es el valor medio y la varianza de la variable Wr.Hnd según el sexo.

```
str(datos2)
```

```
## 'data.frame':    61 obs. of  22 variables:
## $ FechaNac      : Date, format: "2007-12-19" "2007-12-17" ...
## $ Id           : chr  "gipicar" "nihesan" "mapeso5" "zarjuan" ...
```

```
## $ Age      : chr "18" "18" "18" "18" ...
## $ Sex      : chr "F" "M" "M" "M" ...
## $ Wr.Hnd   : chr "19" "22" "19" "18" ...
## $ NW.Hnd   : chr "Derecha" "Derecha" "Derecha" "Derecha" ...
## $ Fold     : chr "Derecho" "Derecho" "Izquierdo" "Derecha" ...
## $ Pulse    : chr "71" "70" "55" "54" ...
## $ Clap     : chr "Der s Izd" "Der s Izq" "Izq s Der" "Derecha" ...
## $ Exer     : chr "2" "4" "5" "6" ...
## $ Smoke    : chr "No" "No" "No" "No" ...
## $ Height   : chr "157" "182" "179" "185" ...
## $ ALG      : chr "7,2" "7.5" "NC" "NC" ...
## $ ANM      : chr "6" "8,1" "NC" "7,4" ...
## $ FP       : chr NA NA NA "NC" ...
## $ DCS      : chr "4" "NC" "4" "NC" ...
## $ MD       : chr "6,2" "6,4" "5,7" "7,3" ...
## $ HSt      : chr "3" "2" "2" "0" ...
## $ Hwork    : num 0 0 0 8 3 0 0 25 0 ...
## $ DNI      : chr "73664304L" "54290706B" "23888492W" "54748087Z" ...
## $ Comentarios : chr "Espero que no sea tan teórica como DCS." "Por lo pronto mejor que dcs" "De r
## $ EDAD_decimales: num 18.1 18.1 18.1 18.2 18.2 ...
```

```
datos2$Wr.Hnd<-as.numeric(datos2$Wr.Hnd)
```

```
## Warning: NAs introducidos por coerción
```

```
wr<- datos2 %>% group_by(Sex)%>%
  summarise(
    Media= mean(Wr.Hnd, na.rm=TRUE),
    Varianza= var(Wr.Hnd, na.rm=TRUE)
  )
```

```
wr
```

```
## # A tibble: 3 x 3
##   Sex   Media Varianza
##   <chr> <dbl>   <dbl>
## 1 Exer  NaN      NA
## 2 F     18.3     4.20
## 3 M     20.0     1.78
```

e. Determina si existe relación entre el sexo y la mano con la que se escribe (NW.Hnd)

```
# Son dos variables categóricas, entonces podemos utilizar varias
```

```
datos2$NW.Hnd <- tolower(datos2$NW.Hnd)
```

```
chisq.test(datos2$Sex, datos2$NW.Hnd)
```

```
## Warning in chisq.test(datos2$Sex, datos2$NW.Hnd): Chi-squared approximation may
## be incorrect
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  datos2$Sex and datos2$NW.Hnd
## X-squared = 0.65904, df = 1, p-value = 0.4169

# Vemos que p-value = 0.4169, por tanto aceptamos la hipótesis de que son independientes.
```

- f. Existe una relación lineal entre la altura (Height) y la distancia del extremo del meñique al extremo del pulgar de la mano con la que escribimos (Wr.Hnd)

```
datos2$Height<-as.numeric(datos2$Height)

datos2$Wr.Hnd<-as.numeric(datos2$Wr.Hnd)

cor(datos2$Height, datos2$Wr.Hnd, use= "complete.obs", method= "pearson")

## [1] 0.3407237

# Nos da 0.3407237, y vemos que sí que existe pero no es tan fuerte.
```

- g. El identificador de Hampel detecta algún outlier en la variable altura.

```
madm <- function(x, na.rm=T) {
  1.4826*median(abs(x-median(x, na.rm = na.rm)), na.rm = na.rm)}

# Identificador Hampel
reglahampel <- function(x) {
  #Calcula la mediana y la MADM (Median Absolute Deviation from the Median),
  #excluyendo NA.
  median_x <- median (x, na.rm = TRUE)
  mad_m <- madm(x)
  #Calculamos el límite superior e inferior.
  upper_limit <- median_x + 3 * mad_m
  lower_limit <- median_x - 3 * mad_m
  #Identificamos los outliers
  outliers1 <- x > upper_limit | x < lower_limit
  return (outliers1)}

reglahampel(datos2$Height)

## [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [13] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [25] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [37] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [49] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [61] NA
```

```
# Vemos que no existe ningún outliers en la variable "Height".
```

- h. Considera la asignatura FP. Si queremos realizar una imputación generalizada usando la media, ¿qué valor deberíamos utilizar ?

```
#Sustituir los valores faltantes por la media de FP.
```

```
datos2$FP<-as.numeric(datos2$FP)
```

```
## Warning: NAs introducidos por coerción
```

```
media_FP<-mean(datos2$FP, na.rm=TRUE)
media_FP
```

```
## [1] 6.28
```

```
Imp<- datos2 %>% filter(is.na(FP))
```

```
# imputación por la media
```

```
Imputacion_datos2 <- datos2 %>%
  mutate(FP = ifelse(
    is.na(FP),
    media_FP,
    FP
  ))
```

```
any(is.na(Imputacion_datos2$FP))
```

```
## [1] FALSE
```

- i. Define una nueva variable (PulseCat) a partir del ritmo cardíaco (Pulse), con dos valores PulseH, si $Pulse \geq 65$ y PulseL si $Pulse < 65$. ¿Qué valores utilizarías para imputar los valores faltantes de las notas de FP, dependiendo del valor de PulseCat (imputación por casos similares)

```
datos2$Pulse <- as.numeric(datos2$Pulse)
```

```
Pulse<-datos2%>% mutate(
  PulseCat= if_else(
    Pulse >= 65,
    "PulseH",
    "PulseL"))
```

```
# Valores de imputación por grupo
```

```
imputacion_FP <- Pulse %>%
  group_by(PulseCat) %>%
  summarise(
    media_FP = mean(FP, na.rm = TRUE))
```

```
imputacion_FP
```

```
## # A tibble: 3 x 2
##   PulseCat media_FP
##   <chr>      <dbl>
## 1 PulseH      7.8
## 2 PulseL      5.27
## 3 <NA>        NaN
```

```
# La media de las notas de FP de cada valor segun tengan PulseH o PulseL
```

- j. ¿Qué podemos decir, como científicos de datos, ante esta frase referida a nuestros datos ? “El ritmo cardíaco está ligado con la cantidad de sangre que llega al cerebro, por tanto existirá una relación lineal directa esta esta variable y las calificaciones obtenidas en ALG”

```
# 2 variables numéricas.
```

```
class(datos2$Pulse)
```

```
## [1] "numeric"
```

```
class(datos2$ALG)
```

```
## [1] "character"
```

```
datos2$ALG<- as.numeric(datos2$ALG)
```

```
## Warning: NAs introducidos por coerción
```

```
# Utilizamos la correlación de Pearson o de Speraman.
```

```
cor(datos2$Pulse, datos2$ALG, use="complete.obs", method= "spearman")
```

```
## [1] 0.2784835
```

Vemos que es una relación positiva pero muy cercana a 0, por tanto no podemos afirmar que exista una relación directa entre estas dos variables.